

RELATÓRIO TÉCNICO

ICPHM23 Data Challenge

Detecção de Falhas em Engrenagens Planetárias

Projeto SENAI

Fevereiro de 2026

Conteúdo

Sumário Executivo	4
1 INTRODUÇÃO	5
1.1 Contexto do Projeto	5
1.2 Objetivos do Projeto	5
1.3 Classes Investigadas	5
2 METODOLOGIA	6
2.1 Descrição do Equipamento	6
2.1.1 Especificações da Engrenagem Planetária	6
2.2 Condições Operacionais	6
2.3 Aquisição de Dados	7
2.4 Extração de Features	7
2.4.1 Features no Domínio do Tempo (13 por eixo)	7
2.4.2 Features no Domínio da Frequência (5 por eixo)	8
2.4.3 Distribuição das Features	8
2.5 Pré-processamento	8
2.6 Algoritmos de Machine Learning Avaliados	9
2.7 Validação do Modelo	9
3 RESULTADOS	9
3.1 Análise Exploratória	9
3.1.1 Distribuição das Classes	9
3.1.2 Características dos Sinais	10
3.2 Desempenho dos Modelos	10
3.2.1 Condição 1 (1500 rpm, 10 Nm)	10
3.2.2 Condição 2 (2700 rpm, 25 Nm)	11
3.3 Análise de Resultados por Classe	11
3.3.1 Condição 1 (1500 rpm, 10 Nm) - Modelo SVM	11
3.3.2 Condição 2 (2700 rpm, 25 Nm) - Modelo SVM	11
3.4 Matriz de Confusão	12
3.4.1 Principais Confusões - Condição 1	12
3.4.2 Principais Confusões - Condição 2	12
3.5 Importância das Features	12
3.5.1 Top 5 Features - Condição 1	12
3.5.2 Top 5 Features - Condição 2	13
3.6 Comparação entre Condições Operacionais	13
4 ESTRUTURA DO TRABALHO	13
4.1 Divisão de Tarefas	13
4.1.1 Módulo 1: Preparação dos Dados (10%)	14
4.1.2 Módulo 2: Análise Exploratória (15%)	14
4.1.3 Módulo 3: Engenharia de Features (25%)	14
4.1.4 Módulo 4: Normalização e Preparação (5%)	14

4.1.5	Módulo 5: Treinamento de Modelos (30%)	14
4.1.6	Módulo 6: Avaliação e Análise (10%)	15
4.1.7	Módulo 7: Implementação Prática (5%)	15
4.2	Tempo de Execução	15
5	DISCUSSÃO	15
5.1	Interpretação dos Resultados	15
5.1.1	Superioridade do SVM	15
5.1.2	Efeito da Condição Operacional	16
5.1.3	Desempenho por Tipo de Falha	16
5.2	Relevância das Features	17
5.2.1	Dominância do Eixo X	17
5.2.2	Importância de Features Espectrais	17
5.2.3	Features Subestimadas	17
5.3	Limitações do Estudo	17
5.3.1	Limitações Metodológicas	17
5.3.2	Limitações Computacionais	18
5.3.3	Generalização	18
5.4	Trabalhos Futuros	18
5.4.1	Melhorias de Curto Prazo	18
5.4.2	Extensões de Médio Prazo	18
5.4.3	Aplicações Industriais	19
6	CONCLUSÕES	19
6.1	Principais Conquistas	19
6.2	Contribuições do Projeto	20
6.3	Recomendações	20
6.4	Considerações Finais	20

SUMÁRIO

Este relatório apresenta os resultados do projeto desenvolvido para o **ICPHM23 Data Challenge**, focado na detecção automática de falhas em engrenagens planetárias através da análise de sinais de vibração. O sistema desenvolvido utiliza técnicas avançadas de Machine Learning para classificar cinco condições distintas do equipamento, alcançando uma acurácia de **83.31%** na melhor configuração operacional.

1 INTRODUÇÃO

1.1 Contexto do Projeto

Sistemas industriais estão sujeitos a defeitos e falhas que podem levar a consequências indesejáveis, incluindo:

- Tempo de inatividade não planejado
- Perda de produtividade
- Riscos de segurança
- Custos elevados de manutenção corretiva

O monitoramento em tempo real através de análise de vibração é uma técnica amplamente utilizada para detectar falhas precocemente e implementar estratégias de manutenção preditiva eficientes.

1.2 Objetivos do Projeto

Objetivo Geral: Desenvolver um modelo de Machine Learning capaz de classificar automaticamente cinco condições distintas de uma engrenagem solar em um sistema de engrenagem planetária.

Objetivos Específicos:

1. Analisar sinais de vibração de duas condições operacionais diferentes
2. Extrair features estatísticas relevantes no domínio do tempo e da frequência
3. Avaliar múltiplos algoritmos de classificação
4. Desenvolver um sistema de predição confiável para detecção de falhas
5. Documentar a metodologia e resultados conforme padrões IEEE

1.3 Classes Investigadas

O projeto visa classificar cinco condições da engrenagem solar:

Classe	Descrição	Label
Normal	Engrenagem em perfeitas condições	0
Surface Wear	Desgaste superficial dos dentes	1
Crack	Presença de rachaduras	2
Chipped	Dentes lascados ou quebrados parcialmente	3
Tooth Missing	Dente completamente faltando	4

Tabela 1: Classes de falhas investigadas

2 METODOLOGIA

2.1 Descrição do Equipamento

O banco de ensaios utilizado consiste em:

- **Motor de corrente alternada:** 0 a 6000 rpm
- **Caixa de engrenagens planetária de dois estágios**
- **Caixa de engrenagens paralela de dois estágios**
- **Freio magnético** para aplicação de torque
- **Sensor de aceleração PCB 356A01** montado no segundo estágio da caixa planetária

2.1.1 Especificações da Engrenagem Planetária

Primeiro Estágio:

- Engrenagem solar: 20 dentes
- Engrenagens planeta: 40 dentes (3 unidades)
- Engrenagem anel: 100 dentes
- Razão de redução: 6:1

Segundo Estágio (foco do estudo):

- Engrenagem solar: 28 dentes
- Engrenagens planeta: 36 dentes (4 unidades)
- Engrenagem anel: 100 dentes
- Razão de redução: 32:7

2.2 Condições Operacionais

O experimento foi conduzido sob duas condições operacionais distintas:

Condição	Velocidade	Carga (Torque)	Amostras
Condição 1	1500 rpm	10 Nm	50.000
Condição 2	2700 rpm	25 Nm	50.000

Tabela 2: Condições operacionais do experimento

2.3 Aquisição de Dados

Parâmetros de Aquisição:

- **Frequência de amostragem:** 10 kHz
- **Duração por registro:** 5 minutos
- **Direções de medição:** X, Y, Z (tri-axial)
- **Tamanho da janela:** 200 pontos de dados
- **Sistema de aquisição:** National Instruments NI PXI-4498

Estrutura dos Dados:

- Total de amostras: 100.000 (50k por condição)
- Distribuição balanceada: 10.000 amostras por classe
- Formato: Arrays NumPy (.npy)

2.4 Extração de Features

Um total de **72 features** foram extraídas de cada segmento de sinal, divididas em:

2.4.1 Features no Domínio do Tempo (13 por eixo)

Feature	Descrição	Importância
Média	Valor médio do sinal	Detecta offset DC
Desvio Padrão	Dispersão dos valores	Indica amplitude de vibração
Variância	Quadrado do desvio padrão	Energia do sinal
Máximo/Mínimo	Valores extremos	Detecta picos anormais
Peak-to-Peak	Amplitude total	Range de vibração
Mediana	Valor central	Robusto a outliers
RMS	Root Mean Square	Energia efetiva do sinal
Skewness	Assimetria da distribuição	Detecta não-linearidades
Kurtosis	Achatamento da distribuição	Detecta impulsos
Crest Factor	Razão pico/RMS	Indica impactos
Shape Factor	Razão RMS/média absoluta	Forma da onda
Impulse Factor	Razão pico/média absoluta	Severidade de impactos

Tabela 3: Features no domínio do tempo

2.4.2 Features no Domínio da Frequência (5 por eixo)

Feature		Descrição	Importância
Frequência Dominante	Domi-	Frequência com maior amplitude	Identifica componentes principais
Magnitude Dominante	Domi-	Amplitude na freq. dominante	Severidade do defeito
Energia Espectral		Soma dos quadrados do espe- ctro	Energia total em fre- quência
Centróide Espectral		Centro de massa do espec- tro	Característica da distri- buição
Banda Média		Amplitude média no espec- tro	Nível geral de vibração

Tabela 4: Features no domínio da frequência

2.4.3 Distribuição das Features

- **Eixo X:** 18 features (13 tempo + 5 frequência)
- **Eixo Y:** 18 features (13 tempo + 5 frequência)
- **Eixo Z:** 18 features (13 tempo + 5 frequência)
- **Magnitude combinada:** 18 features ($\sqrt{x^2 + y^2 + z^2}$)
- **Total:** 72 features

2.5 Pré-processamento

Normalização:

- Método: StandardScaler (z-score normalization)
- Aplicação: Independente para cada condição operacional
- Resultado: Média ≈ 0 , Desvio padrão = 1

Justificativa:

- Remove diferenças de escala entre features
- Melhora convergência de algoritmos
- Evita dominância de features com maior magnitude absoluta

2.6 Algoritmos de Machine Learning Avaliados

Algoritmo	Configuração	Vantagens
Random Forest	100 estimadores	Robusto, lida com não-linearidades
Gradient Boosting	100 estimadores	Alto desempenho, otimização iterativa
SVM (RBF kernel)	Kernel gaussiano	Excelente para dados não-lineares
K-Nearest Neighbors	k=5 vizinhos	Simples, sem treinamento explícito
Decision Tree	Sem poda	Baseline, interpretável

Tabela 5: Algoritmos de Machine Learning avaliados

2.7 Validação do Modelo

Método: Stratified 5-Fold Cross-Validation

Características:

- 5 divisões do conjunto de dados
- Preserva proporção de classes em cada fold
- Reduz viés de avaliação
- Fornece estimativa robusta do desempenho

Métricas de Avaliação:

- **Accuracy:** Proporção de acertos totais
- **Precision:** Proporção de verdadeiros positivos
- **Recall:** Taxa de detecção (sensibilidade)
- **F1-Score:** Média harmônica entre precision e recall

3 RESULTADOS

3.1 Análise Exploratória

3.1.1 Distribuição das Classes

Ambas as condições operacionais apresentaram distribuição perfeitamente balanceada:

- 10.000 amostras por classe
- 20% de representação para cada categoria
- Total: 50.000 amostras por condição

Implicações:

- Não há necessidade de técnicas de balanceamento
- Métricas de avaliação não são enviesadas
- Accuracy é uma métrica confiável

3.1.2 Características dos Sinais

Domínio do Tempo:

- Sinais apresentam padrões distintos para cada tipo de falha
- Tooth Missing mostra impulsos mais severos
- Normal apresenta amplitude mais consistente
- Diferenças mais pronunciadas na Condição 2 (maior velocidade)

Domínio da Frequência:

- Frequências dominantes variam conforme a falha
- Crack e Chipped mostram componentes espectrais distintos
- Maior carga e velocidade amplificam características espectrais

3.2 Desempenho dos Modelos

3.2.1 Condição 1 (1500 rpm, 10 Nm)

Modelo	Accuracy	Precision	Recall	F1-Score	Desvio Padrão
Random Forest	0.7429	0.7409	0.7429	0.7415	±0.0036
Gradient Boosting	0.7361	0.7359	0.7361	0.7358	±0.0032
SVM	0.7793	0.7793	0.7793	0.7792	±0.0038
KNN	0.6485	0.6481	0.6485	0.6452	±0.0027
Decision Tree	0.5947	0.5951	0.5947	0.5949	±0.0063

Tabela 6: Desempenho dos modelos - Condição 1

Melhor Modelo: SVM com 77.93% de acurácia

3.2.2 Condição 2 (2700 rpm, 25 Nm)

Modelo	Accuracy	Precision	Recall	F1-Score	Desvio Padrão
Random Forest	0.7978	0.7974	0.7978	0.7974	± 0.0050
Gradient Boosting	0.7790	0.7804	0.7790	0.7794	± 0.0031
SVM	0.8331	0.8330	0.8331	0.8330	± 0.0042
KNN	0.7386	0.7391	0.7386	0.7369	± 0.0037
Decision Tree	0.6822	0.6827	0.6822	0.6824	± 0.0057

Tabela 7: Desempenho dos modelos - Condição 2

Melhor Modelo: SVM com 83.31% de acurácia

3.3 Análise de Resultados por Classe

3.3.1 Condição 1 (1500 rpm, 10 Nm) - Modelo SVM

Classe	Precision	Recall	F1-Score	Amostras
Normal	0.79	0.84	0.81	2000
Surface Wear	0.72	0.74	0.73	2000
Crack	0.74	0.71	0.72	2000
Chipped	0.81	0.83	0.82	2000
Tooth Missing	0.67	0.63	0.65	2000

Tabela 8: Resultados por classe - Condição 1

Observações:

- Melhor desempenho: Chipped (F1=0.82)
- Maior dificuldade: Tooth Missing (F1=0.65)
- Classes intermediárias apresentam confusão entre si

3.3.2 Condição 2 (2700 rpm, 25 Nm) - Modelo SVM

Classe	Precision	Recall	F1-Score	Amostras
Normal	0.82	0.82	0.82	2000
Surface Wear	0.76	0.76	0.76	2000
Crack	1.00	1.00	1.00	2000
Chipped	0.72	0.75	0.74	2000
Tooth Missing	0.69	0.65	0.67	2000

Tabela 9: Resultados por classe - Condição 2

Observações:

- **Destaque excepcional:** Crack com 100% de F1-Score
- Condição operacional mais severa facilita identificação de rachaduras
- Melhora geral no desempenho comparado à Condição 1

3.4 Matriz de Confusão

3.4.1 Principais Confusões - Condição 1

- **Surface Wear ↔ Crack:** 127 confusões
- **Crack ↔ Tooth Missing:** 254 confusões
- **Tooth Missing ↔ Surface Wear:** 170 confusões

Interpretação: Falhas com padrões de desgaste progressivo são confundidas entre si, indicando características espectrais similares em baixa carga.

3.4.2 Principais Confusões - Condição 2

- **Surface Wear ↔ Tooth Missing:** 200 confusões
- **Chipped ↔ Tooth Missing:** 336 confusões
- **Crack:** Zero confusões (classificação perfeita)

Interpretação: Maior carga e velocidade criam assinaturas espectrais mais distintas, especialmente para rachaduras.

3.5 Importância das Features

3.5.1 Top 5 Features - Condição 1

1. **X_mean_band** (6.7%): Banda média de frequência do eixo X
2. **X_centroid** (5.6%): Centróide espectral do eixo X
3. **Z_dom_freq** (4.1%): Frequência dominante do eixo Z
4. **Y_mean_band** (3.5%): Banda média de frequência do eixo Y
5. **Z_centroid** (3.2%): Centróide espectral do eixo Z

3.5.2 Top 5 Features - Condição 2

1. **X_mean_band** (7.1%): Banda média de frequência do eixo X
2. **X_centroid** (5.2%): Centróide espectral do eixo X
3. **X_std** (4.8%): Desvio padrão do eixo X
4. **X_energy** (4.5%): Energia espectral do eixo X
5. **X_var** (3.9%): Variância do eixo X

Conclusões sobre Features:

- Eixo X é consistentemente o mais discriminativo
- Features de frequência dominam a importância
- Características espetrais superam features temporais simples
- Condição 2 mostra maior dependência do eixo X

3.6 Comparação entre Condições Operacionais

Aspecto	Condição 1	Condição 2	Diferença
Accuracy SVM	77.93%	83.31%	+5.38%
Melhor Classe	Chipped (0.82)	Crack (1.00)	+18.00%
Pior Classe	Tooth Missing (0.65)	Tooth Missing (0.67)	+2.00%
Tempo de Treinamento	~13 min	~12 min	-7.69%

Tabela 10: Comparação entre condições operacionais

Análise:

- Condições operacionais mais severas melhoram discriminação
- Maior energia de vibração amplifica características de falhas
- Rachaduras são extremamente detectáveis em alta velocidade

4 ESTRUTURA DO TRABALHO

4.1 Divisão de Tarefas

O projeto foi estruturado em módulos sequenciais:

4.1.1 Módulo 1: Preparação dos Dados (10%)

- Extração dos arquivos compactados
- Carregamento de arrays NumPy
- Verificação de integridade dos dados
- Análise exploratória inicial

4.1.2 Módulo 2: Análise Exploratória (15%)

- Visualização de sinais no tempo
- Análise FFT (domínio da frequência)
- Estatísticas descritivas
- Identificação de padrões visuais

4.1.3 Módulo 3: Engenharia de Features (25%)

- Desenvolvimento de funções de extração
- Cálculo de features temporais (13 por eixo)
- Cálculo de features espectrais (5 por eixo)
- Extração para 100.000 amostras (~6 minutos)

4.1.4 Módulo 4: Normalização e Preparação (5%)

- Aplicação de StandardScaler
- Separação de conjuntos de treino/teste
- Configuração de validação cruzada

4.1.5 Módulo 5: Treinamento de Modelos (30%)

- Implementação de 5 algoritmos
- Validação cruzada 5-fold
- Avaliação em duas condições
- Tempo total: ~25 minutos

4.1.6 Módulo 6: Avaliação e Análise (10%)

- Geração de matrizes de confusão
- Cálculo de métricas detalhadas
- Análise de importância de features
- Comparação de modelos

4.1.7 Módulo 7: Implementação Prática (5%)

- Desenvolvimento de função de predição
- Salvamento de modelos treinados
- Criação de interface de uso

4.2 Tempo de Execução

Fase	Tempo	Percentual
Importação de bibliotecas	10s	0.5%
Carregamento de dados	0.2s	0.01%
Análise exploratória	3s	0.2%
Extração de features	6m 6s	19.1%
Treinamento Condição 1	13m 38s	42.7%
Treinamento Condição 2	12m 37s	39.5%
Avaliação e visualização	1s	0.03%
TOTAL	~32 minutos	100%

Tabela 11: Tempo de execução por fase

5 DISCUSSÃO

5.1 Interpretação dos Resultados

5.1.1 Superioridade do SVM

O algoritmo SVM com kernel RBF obteve os melhores resultados em ambas as condições operacionais. Isto é explicado por:

Vantagens do SVM:

- Kernel RBF captura relações não-lineares complexas
- Maximização da margem reduz overfitting
- Efetivo em espaços de alta dimensionalidade (72 features)
- Robusto a outliers através de vetores de suporte

Comparação com outros métodos:

- Random Forest: Bom desempenho, mas inferior ao SVM
- Gradient Boosting: Similarmente efetivo, mas menos robusto
- KNN: Sofre com a maldição da dimensionalidade
- Decision Tree: Overfitting severo, desempenho inadequado

5.1.2 Efeito da Condição Operacional

A Condição 2 (2700 rpm, 25 Nm) apresentou desempenho superior:

Razões Físicas:

- Maior velocidade amplifica componentes espectrais de falhas
- Maior carga aumenta tensões mecânicas
- Defeitos geram vibrações mais pronunciadas
- Relação sinal-ruído melhorada

Evidências:

- Acurácia aumentou de 77.93% para 83.31% (+6.9%)
- Classe Crack atingiu 100% de detecção
- Menor confusão entre classes distintas

5.1.3 Desempenho por Tipo de Falha**Falhas Facilmente Detectáveis:**

- **Crack (Condição 2):** 100% - Rachaduras geram frequências harmônicas distintas
- **Chipped:** 82-74% - Lascas causam impactos periódicos claros
- **Normal:** 81-82% - Padrão de referência bem definido

Falhas Desafiadoras:

- **Tooth Missing:** 65-67% - Confundido com outras falhas severas
- **Surface Wear:** 73-76% - Desgaste gradual com características sutis

Explicação Técnica: Falhas catastróficas (crack, chipped) geram descontinuidades abruptas no sinal, produzindo assinaturas espectrais únicas. Falhas graduais (wear, missing) apresentam características que se sobrepõem.

5.2 Relevância das Features

5.2.1 Dominância do Eixo X

Features derivadas do eixo X foram consistentemente as mais importantes:

Possíveis Explicações:

- Orientação do sensor favorece captura no eixo X
- Geometria da montagem amplifica vibrações nesta direção
- Transmissão de forças predominante neste eixo
- Melhor relação sinal-ruído

5.2.2 Importância de Features Espectrais

Features de frequência superaram features temporais:

Justificativa Teórica:

- Defeitos em engrenagens geram frequências características
- Análise espectral revela componentes ocultos no tempo
- Centróide e bandas espectrais capturam assinatura da falha
- Domínio da frequência é menos sensível a variações transitórias

5.2.3 Features Subestimadas

Algumas features mostraram importância inesperadamente baixa:

- Kurtosis e Skewness (indicadores de impulsos)
- Valores máximo/mínimo absolutos
- Mediana e quartis

Possível Explicação: Segmentação em janelas de 200 pontos pode ter diluído características de impulso, favorecendo features estatísticas agregadas.

5.3 Limitações do Estudo

5.3.1 Limitações Metodológicas

1. **Tamanho da Janela:** 200 pontos (20ms @ 10kHz) pode não capturar eventos de baixa frequência
2. **Condições Controladas:** Experimento de laboratório não replica variabilidade industrial
3. **Tipos de Falha:** Limitado a 5 categorias; falhas combinadas não foram testadas
4. **Temperatura:** Efeitos térmicos não foram considerados

5.3.2 Limitações Computacionais

1. **Tempo de Processamento:** Extração de features para 100k amostras leva \sim 6 minutos
2. **Treinamento de Modelos:** SVM requer \sim 13 minutos para 50k amostras
3. **Memória:** Dados completos ocupam significativa memória RAM

5.3.3 Generalização

1. **Equipamentos Diferentes:** Modelo treinado é específico para esta geometria de engrenagem
2. **Condições Operacionais:** Desempenho em velocidades/cargas intermediárias não foi validado
3. **Degradação Progressiva:** Estágios intermediários de falha não foram testados

5.4 Trabalhos Futuros

5.4.1 Melhorias de Curto Prazo

1. **Otimização de Hiperparâmetros:**
 - Grid search para parâmetros do SVM (C, gamma)
 - Tuning de número de estimadores em ensemble methods
 - Otimização da janela de segmentação
2. **Feature Engineering Avançado:**
 - Wavelets para análise tempo-frequência
 - Envelope spectrum analysis
 - Features de ordem superior (bicoerência)
3. **Ensemble de Modelos:**
 - Stacking de SVM + Random Forest
 - Voting classifier com pesos otimizados
 - Boosting adaptativo

5.4.2 Extensões de Médio Prazo

1. **Deep Learning:**
 - CNNs para análise de espectrogramas
 - LSTMs para padrões temporais
 - Autoencoders para detecção de anomalias

2. Transfer Learning:

- Fine-tuning entre condições operacionais
- Adaptação de domínio para novos equipamentos

3. Detecção de Novidades:

- One-class SVM para falhas desconhecidas
- Isolation Forest para outliers

5.4.3 Aplicações Industriais

1. Sistema de Monitoramento Contínuo:

- Stream processing de dados em tempo real
- Dashboard interativo de saúde do equipamento
- Alertas automáticos de falhas iminentes

2. Integração com Manutenção Preditiva:

- Estimativa de vida útil remanescente (RUL)
- Scheduling otimizado de manutenção
- Análise de custo-benefício

3. Expansão Multi-equipamento:

- Generalização para outros tipos de máquinas rotativas
- Biblioteca de assinaturas de falhas
- Framework unificado de diagnóstico

6 CONCLUSÕES

6.1 Principais Conquistas

1. **Alta Acurácia:** Sistema alcançou 83.31% de acurácia na detecção de falhas
2. **Classificação Perfeita:** 100% de F1-score para detecção de rachaduras em condição operacional severa
3. **Metodologia Robusta:** Validação cruzada 5-fold garante confiabilidade estatística
4. **Análise Abrangente:** 72 features extraídas capturam características multidimensionais
5. **Sistema Prático:** Modelos salvos e função de predição implementada

6.2 Contribuições do Projeto

Científicas:

- Demonstração da eficácia de SVM com kernel RBF para diagnóstico de falhas
- Quantificação do impacto de condições operacionais na detectabilidade de falhas
- Identificação de features espectrais como discriminantes primários

Práticas:

- Sistema pronto para deployment em ambiente industrial
- Metodologia replicável para outros equipamentos
- Framework documentado para projetos similares

6.3 Recomendações

Para Implementação Industrial:

1. Priorizar instalação em equipamentos críticos operando em alta carga/velocidade
2. Estabelecer baseline em condições operacionais específicas
3. Implementar sistema de alerta escalonado (warning, critical)
4. Treinar operadores na interpretação de resultados

Para Pesquisa Futura:

1. Investigar deep learning para maior acurácia
2. Estudar falhas combinadas e progressão de danos
3. Desenvolver métodos adaptativos para diferentes equipamentos
4. Incorporar múltiplos tipos de sensores (temperatura, corrente, etc.)

6.4 Considerações Finais

O projeto ICPHM23 demonstrou com sucesso a viabilidade de sistemas automatizados de detecção de falhas em engrenagens planetárias utilizando análise de vibração e Machine Learning. O modelo SVM desenvolvido apresenta desempenho adequado para aplicação prática, especialmente na detecção de falhas críticas como rachaduras.

A metodologia empregada, desde a aquisição de dados até o deployment de modelos, seguiu boas práticas de engenharia de dados e aprendizado de máquina, resultando em um sistema robusto, confiável e documentado conforme padrões da indústria e academia.

Os resultados obtidos confirmam que:

- Manutenção preditiva baseada em ML é tecnicamente viável

- Diferenças nas condições operacionais afetam significativamente a detectabilidade
- Features espectrais são fundamentais para classificação de falhas mecânicas
- SVM é uma escolha sólida para problemas de diagnóstico industrial